

UNIVERSIDAD DEL VALLE DE GUATEMALA

Informe final de obtención y limpieza de datos

Establecimientos educativos de Guatemala · Nivel Diversificado

PROYECTO 1 · ENTREGA FINAL

Integrantes

ABBY SOFIA DONIS AGREDA — 22440

PABLO DANIEL BARILLAS MORENO — 22193

JORGE PALACIOS — 231385

ROBERTO EMILIANO OTONIEL CAMPOSECO TORRES — 23968

Curso: CC3084 — Data Science · Semestre II 2026

Versión final 2.0 · 17 de julio de 2026

Resumen ejecutivo

Se construyó un flujo reproducible para diagnosticar, limpiar, integrar y documentar los datos de establecimientos educativos autorizados por el Ministerio de Educación de Guatemala en el nivel Diversificado. El archivo crudo consolidado contiene 11,603 registros y 17 variables. Todas las columnas se cargaron como texto para impedir pérdidas de ceros iniciales en códigos, distritos y teléfonos.

La ejecución conservó las 11,603 filas: CODIGO es único y no se detectaron duplicados exactos. La salida completa contiene 59 variables, incluidas columnas originales, versiones limpias, indicadores de ausencia, códigos nominales y metadatos. Se documentaron 13,031 pares candidatos a duplicado parcial sin eliminar registros automáticamente. Los 27 controles definidos finalizaron satisfactoriamente.

Registros	Crudas	Finales	Eliminadas	Controles
11,603	17	59	0	27/27

Decisión central: No se sobrescriben nombres ni etiquetas originales. La presentación corregida se guarda en columnas *_LIMPIO y la fuente permanece en *_ORIGINAL. Las claves sin tildes se usan solo para comparación, nunca para redactar informes.

Contenido del informe

Sección	Contenido
1	Correspondencia con los lineamientos
2	Fuente, alcance y unidad de observación
3	Arquitectura reproducible y archivos crudos
4	Diagnóstico del estado inicial y duplicados parciales
5	Plan ejecutado y reglas por variable
6	Resultados y calidad antes/después
7	Análisis descriptivo del conjunto final
8	Control de calidad, consistencia y reproducibilidad
9	Libro de códigos, metadatos y entregables
10	Limitaciones, conclusiones y referencias

1. Correspondencia con los lineamientos

El trabajo se desarrolló con base en el documento “Proyecto 1. Obtención y Limpieza de datos” y en el buscador oficial del MINEDUC. La siguiente matriz muestra la evidencia concreta incluida en la entrega.

Criterio	Evidencia	Estado
Carga correcta	Notebook ejecutado; carga string; validación de 11,603 × 17 y esquema esperado.	Cumplido
Análisis crudo	Perfil por variable: tipo, únicos, faltantes técnicos/semánticos, porcentaje, dominios, formatos y duplicados.	Cumplido
Limpieza y explicación	Plan para 17 variables, bitácora por cambio, tabla de transformaciones, razones, riesgos y 27 pruebas.	Cumplido
Duplicados parciales	TF-IDF de n-gramas, umbral 0.92, 13,031 pares, evidencia auxiliar y decisión por par; 0 eliminaciones automáticas.	Cumplido
Consistencia cruzada	Siete verificaciones geográficas, de indicadores y de teléfonos, todas sin inconsistencias.	Cumplido
Calidad antes/después	Trece métricas comparables, incluidos faltantes, formatos, categorías inconsistentes, duplicados y errores corregidos.	Cumplido
Libro de códigos	DOCX/PDF/Markdown y Excel con 59 variables, dominios, tratamientos, derivaciones, fecha, fuente y versión.	Cumplido
Conjunto limpio	CSV nacional completo de 11,603 × 59 y vista analítica de 11,603 × 42.	Cumplido

2. Fuente, alcance y unidad de observación

La fuente declarada es el buscador oficial de establecimientos educativos del Ministerio de Educación de Guatemala: http://www.mineduc.gob.gt/BUSCAESTABLECIMIENTO_GE/

El filtro de interés es Nivel Escolar = Diversificado. La unidad de observación es el código de servicio educativo autorizado; por ello, dos filas con nombres parecidos no necesariamente describen el mismo servicio. CODIGO se utiliza como llave y no el nombre del establecimiento.

Ciudad Capital: El portal presenta Ciudad Capital como origen separado de Guatemala. Se conservaron 23 categorías de origen y se derivó una vista de 22 departamentos, en la que los 2,161 registros de Ciudad Capital se agregan a Guatemala. Las zonas capitalinas se mantienen en columnas separadas.

2.1 Metadatos del snapshot

Metadato	Valor
Fuente	MINEDUC - Búsqueda de centros educativos autorizados
URL	http://www.mineduc.gob.gt/BUSCAESTABLECIMIENTO_GE/

Metadato	Valor
Fecha de extracción	2026-07-10
Nota de la fecha	Fecha del archivo crudo preservado; la hora exacta no estaba incorporada en el CSV.
Fecha de procesamiento	2026-07-17
Versión limpia	2.0.0
SHA-256 del crudo	e7b9f1056e17fdf7eb994b8dc584f22671cdd3e78c388c85b2f547a2bae033af

La fecha de extracción se toma del archivo crudo preservado. El CSV no incorporaba una hora interna de extracción, por lo que esta limitación se declara en lugar de inventar un timestamp. La huella SHA-256 permite comprobar que el snapshot no cambió durante el procesamiento.

2.2 Catálogo territorial y cobertura

SEGEPLAN reporta 340 municipios para Guatemala en su conjunto territorial 2026. El snapshot MINEDUC contiene 334 códigos municipales con servicios de Diversificado y 22 zonas capitalinas. En consecuencia, el catálogo de este proyecto valida todas las combinaciones que aparecen en el universo analizado, pero no se presenta como listado nacional exhaustivo: seis municipios no aparecen en la consulta utilizada.

Indicador	Resultado
Municipios observados	334
Municipios nacionales de referencia	340
Zonas de Ciudad Capital	22
Departamentos analíticos	22
Origen del catálogo	Snapshot MINEDUC; referencia SEGEPLAN 2026

3. Arquitectura reproducible y archivos crudos

El notebook ejecutado concentra la carga, el diagnóstico, las funciones de normalización, la aplicación de reglas, la generación de salidas y las verificaciones. Cada ejecución vuelve a crear los archivos de datos, resultados y documentación a partir del CSV crudo.

```
df_raw = pd.read_csv(RAW_PATH, dtype="string", keep_default_na=False)
assert df_raw.shape == (11603, 17)
assert df_raw["CODIGO"].nunique() == 11603
assert int(df_raw.duplicated().sum()) == 0
```

El archivo consolidado se particionó por las 23 categorías geográficas publicadas para facilitar la auditoría. Estas particiones son derivaciones del consolidado crudo y no se presentan como descargas independientes. La suma de sus filas es 11,603.

Origen	Filas	Archivo crudo
ALTA VERAPAZ	475	datos_crudos_alta_verapaz.csv
BAJA VERAPAZ	171	datos_crudos_baja_verapaz.csv
CHIMALTENANGO	435	datos_crudos_chimaltenango.csv
CHIQUMULA	239	datos_crudos_chiquimula.csv
CIUDAD CAPITAL	2,161	datos_crudos_ciudad_capital.csv
EL PROGRESO	158	datos_crudos_el_progreso.csv
ESCUINTLA	708	datos_crudos_escuintla.csv
GUATEMALA	1,644	datos_crudos_guatemala.csv
HUEHUETENANGO	591	datos_crudos_huehuetenango.csv
IZABAL	413	datos_crudos_izabal.csv
JALAPA	183	datos_crudos_jalapa.csv
JUTIAPA	392	datos_crudos_jutiapa.csv
PETEN	516	datos_crudos_peten.csv
QUETZALTENANGO	551	datos_crudos_quetzaltenango.csv
QUICHE	322	datos_crudos_quiche.csv
RETALHULEU	364	datos_crudos_retalhuleu.csv
SACATEPEQUEZ	430	datos_crudos_sacatepequez.csv
SAN MARCOS	724	datos_crudos_san_marcos.csv
SANTA ROSA	213	datos_crudos_santa_rosa.csv
SOLOLA	192	datos_crudos_solola.csv
SUCHITEPEQUEZ	437	datos_crudos_suchitepequez.csv
TOTONICAPAN	128	datos_crudos_totonicapan.csv
ZACAPA	156	datos_crudos_zacapa.csv

4. Diagnóstico del estado inicial

4.1 Dimensiones, tipos y unicidad

El conjunto inicial tiene 11,603 filas y 17 variables. Las 17 se cargaron como string. Esta elección es semántica: CODIGO, DISTRITO y TELEFONO pueden contener dígitos, pero son identificadores y no magnitudes numéricas. Se encontraron 11,603 códigos únicos y 0 registros duplicados exactos.

Variable	Tipo	Valores únicos	Faltantes analíticos	%
CODIGO	string	11,603	0	0.00
DISTRITO	string	1,667	522	4.50
DEPARTAMENTO	string	23	0	0.00
MUNICIPIO	string	350	0	0.00
ESTABLECIMIENTO	string	6,170	5	0.04
DIRECCION	string	7,260	87	0.75
TELEFONO	string	6,429	933	8.04
SUPERVISOR	string	1,268	525	4.52
DIRECTOR	string	5,397	2,106	18.15
NIVEL	string	1	0	0.00
SECTOR	string	4	0	0.00
AREA	string	3	3	0.03
STATUS	string	5	0	0.00
MODALIDAD	string	2	0	0.00
JORNADA	string	6	1,072	9.24
PLAN	string	13	0	0.00
DEPARTAMENTAL	string	26	0	0.00

4.2 Valores faltantes

Se distinguieron faltantes técnicos y ausencias semánticas. Los primeros son celdas vacías o marcadores sin contenido; las segundas son rótulos como SIN JORNADA y SIN ESPECIFICAR. En las columnas analíticas estos rótulos se transforman a null, pero la causa se conserva mediante el valor original y un indicador *_INFORMADA.




Figura 1. Faltantes analíticos por campo, generados mediante código.

DIRECTOR registra 2,106 ausencias (18.15%), JORNADA 1,072 (9.24%), TELEFONO 933 (8.04%), SUPERVISOR 525 (4.52%), DISTRITO 522 vacíos técnicos, DIRECCION 87 y ESTABLECIMIENTO 5. Al validar el patrón del distrito se identificaron además 69 formatos incompletos; por ello DISTRITO_LIMPIO tiene 591 null.

4.3 Dominios, formatos e inconsistencias

Grupo	Problema potencial identificado
Identificadores	CODIGO es íntegro y único; DISTRITO tiene vacíos e incompletos; TELEFONO contiene uno, varios o formatos históricos.
Geografía	23 orígenes porque Ciudad Capital está separada; el análisis departamental requiere una derivación de 22 categorías.
Texto	Mayúsculas sostenidas, espacios, signos, abreviaturas y tildes inconsistentes en nombres y direcciones.
Ausencias	SIN JORNADA y SIN ESPECIFICAR describen ausencia, no categorías analíticas reales.
Categorías	SECTOR, STATUS, MODALIDAD, AREA, JORNADA, PLAN y DEPARTAMENTAL requieren etiquetas legibles y códigos nominales estables.
Duplicados	0 duplicados exactos y 0 códigos repetidos; nombres parecidos no justifican eliminar servicios.

4.4 Duplicados exactos y parciales

No se encontraron duplicados exactos ni códigos repetidos. Para localizar coincidencias parciales se bloquearon los registros por departamento y municipio/zona y se comparó el nombre normalizado con

TF-IDF de caracteres de 3 a 5 posiciones y distancia coseno. El umbral de similitud fue 0.92. Este método recupera errores de letras y variantes cercanas sin comparar indiscriminadamente registros de territorios distintos.

Resultado	Cantidad	Criterio
Pares candidatos	13,031	Todos tienen decisión documentada
Conservar: servicios distintos	10,802	Cambian sector, área, modalidad, jornada, plan o departamental
Conservar y revisar	1,307	Coinciden servicio y dirección o teléfono, pero los códigos son distintos
Conservar códigos distintos	922	No existe evidencia suficiente para fusionar
Revisión manual recomendada	2,063	Requiere contraste con la fuente oficial antes de una eventual fusión
Filas eliminadas	0	La similitud de nombre nunca autoriza eliminación automática

Regla conservadora: CODIGO identifica un servicio autorizado. Dos nombres iguales pueden corresponder a jornadas, planes, sectores o códigos diferentes. Por esa razón, el archivo de candidatos documenta la revisión, pero el conjunto final conserva todas las filas.

5. Plan ejecutado y reglas por variable

Las reglas se aplicaron de forma conservadora. Unicode NFC, recorte de espacios y presentación ortográfica se ejecutaron en columnas derivadas. Las correcciones léxicas se limitaron a casos respaldados; las claves sin tildes no sustituyen el texto de presentación. A continuación, se documentan problema, regla, razón, riesgo y control para cada variable cruda.

CODIGO

Elemento	Detalle
Problemas encontrados	No presenta faltantes ni repeticiones; el riesgo principal es que el software lo convierta a número o fecha.
Regla ejecutada	Cargar y exportar como texto; comprobar unicidad y patrón; conservarlo como llave del servicio.
Justificación	Los guiones y ceros forman parte del identificador.
Riesgo y mitigación	Conversión automática. Se evita fijando dtype='string' y validando la salida.
Control / evidencia	11,603 valores válidos y únicos; QC02 y QC03 aprobados.

DISTRITO

Elemento	Detalle
Problemas encontrados	522 vacíos técnicos y 69 formatos incompletos; 1,667 valores distintos en la fuente.
Regla ejecutada	Conservar DISTRITO_ORIGINAL; producir DISTRITO_LIMPIO solo si el formato está completo y clasificar la celda como Válido, Vacío o Incompleto.
Justificación	No debe inventarse el fragmento faltante de un código administrativo.
Riesgo y mitigación	Perder un prefijo parcial. Se mantiene original y estado para una revisión posterior.
Control / evidencia	591 null en DISTRITO_LIMPIO, exactamente los esperados; QC08 aprobado.

DEPARTAMENTO

Elemento	Detalle
Problemas encontrados	La fuente tiene 23 orígenes porque Ciudad Capital se publica fuera de Guatemala.
Regla ejecutada	Crear etiqueta legible, conservar DEPARTAMENTO_ORIGINAL, derivar DEPARTAMENTO_ANALISIS de 22 categorías y agregar código territorial de dos dígitos.
Justificación	Evita doble conteo y permite análisis nacional coherente sin perder procedencia.
Riesgo y mitigación	Fusionar orígenes. La columna original y UBICACION_GRUPO mantienen la distinción.
Control / evidencia	23 orígenes, 22 departamentos analíticos y 2,161 filas capitalinas; QC05–QC07 aprobados.

MUNICIPIO

Elemento	Detalle
Problemas encontrados	Combina municipios y zonas capitalinas; nombres en mayúsculas y tildes no uniformes.
Regla ejecutada	Crear MUNICIPIO_LIMPIO, TIPO_UBICACION, ES_CIUADAD_CAPITAL, ZONA_CAPITAL_COD y MUNICIPIO_COD_FUENTE.
Justificación	Separa la semántica de zona y municipio y facilita agrupaciones posteriores.
Riesgo y mitigación	Tratar una zona como municipio. El tipo de ubicación se conserva explícitamente.
Control / evidencia	Las 350 etiquetas crudas permanecen trazables; 22 zonas capitalinas identificadas.

ESTABLECIMIENTO

Elemento	Detalle
Problemas encontrados	6,170 valores únicos, 5 vacíos, mayúsculas sostenidas, tildes y algunos errores evidentes.

Elemento	Detalle
Regla ejecutada	Conservar el original; crear presentación española conservadora y una clave auxiliar sin tildes/puntuación solo para comparar candidatos. No deduplicar por similitud.
Justificación	Los informes necesitan nombres legibles, pero los servicios se distinguen por CODIGO.
Riesgo y mitigación	Corregir indebidamente un nombre propio. Solo se aplican reglas respaldadas y se guarda el original.
Control / evidencia	5 null; ninguna fila eliminada; R05 y QC09 documentan el resultado.

DIRECCION

Elemento	Detalle
Problemas encontrados	7,260 valores únicos, 87 vacíos, abreviaturas, espacios y puntuación heterogéneos.
Regla ejecutada	Normalizar espacios y puntuación de presentación; preservar abreviaturas plausibles; asignar null solo a vacío real o signos aislados.
Justificación	Mejora la lectura sin inventar componentes geográficos.
Riesgo y mitigación	Alterar una referencia válida. DIRECCION_ORIGINAL permanece disponible.
Control / evidencia	87 null en DIRECCION_LIMPIA; QC10 aprobado.

TELEFONO

Elemento	Detalle
Problemas encontrados	933 vacíos; celdas con uno o varios números y 48 formatos no estándar.
Regla ejecutada	Tratar como texto, normalizar candidatos de ocho dígitos, extraer TELEFONO_PRINCIPAL, clasificar TELEFONO_ESTADO y dejar null en TELEFONO_LIMPIO cuando no sea interpretable.
Justificación	Un teléfono no es una cantidad y no debe imputarse.
Riesgo y mitigación	Un formato histórico utilizable podría no satisfacer la regla. TELEFONO_ORIGINAL y el estado conservan la evidencia.
Control / evidencia	10,501 válidos únicos, 121 múltiples, 48 no estándar, 933 vacíos y 981 null analíticos.

SUPERVISOR

Elemento	Detalle
Problemas encontrados	1,268 valores únicos y 525 ausencias; nombres en mayúsculas y tildes variables.
Regla ejecutada	Crear presentación conservadora; null solo para ausencia real; conservar original.
Justificación	Permite lectura institucional sin afirmar identidad entre homónimos.

Elemento	Detalle
Riesgo y mitigación	Sobrecorregir apellidos o fusionar personas. No se asignan identificadores personales.
Control / evidencia	525 null en SUPERVISOR_LIMPIO; QC12 aprobado.

DIRECTOR

Elemento	Detalle
Problemas encontrados	5,397 valores únicos y 2,106 ausencias, incluidos marcadores como '--'.
Regla ejecutada	Convertir marcadores vacíos a null en DIRECTOR_LIMPIO, crear estado y aplicar presentación conservadora.
Justificación	Distingue ausencia de nombre informado.
Riesgo y mitigación	Inferir una persona o alterar apellidos. Se preserva DIRECTOR_ORIGINAL.
Control / evidencia	2,106 null y estado explícito; QC13 aprobado.

NIVEL

Elemento	Detalle
Problemas encontrados	Variable constante con una categoría: DIVERSIFICADO.
Regla ejecutada	Normalizar la etiqueta a Diversificado y verificar que no aparezcan otros niveles.
Justificación	Confirma el alcance definido por el filtro de extracción.
Riesgo y mitigación	Ocultar una descarga mezclada. El control exige una sola categoría.
Control / evidencia	11,603 filas en Diversificado.

SECTOR

Elemento	Detalle
Problemas encontrados	Cuatro categorías válidas, originalmente en mayúsculas.
Regla ejecutada	Crear SECTOR_LIMPIO y SECTOR_COD con catálogo nominal 1–4; conservar etiqueta original.
Justificación	Los códigos estabilizan análisis y filtros sin reemplazar las etiquetas.
Riesgo y mitigación	Interpretar los números como orden. El catálogo declara 'Código nominal'.
Control / evidencia	0 códigos faltantes; QC16 aprobado.

AREA

Elemento	Detalle
Problemas encontrados	URBANA, RURAL y tres filas SIN ESPECIFICAR.
Regla ejecutada	Crear AREA_LIMPIA y AREA_COD; representar SIN ESPECIFICAR como null y AREA_INFORMADA=0; conservar original.
Justificación	SIN ESPECIFICAR no es una tercera área real.
Riesgo y mitigación	Perder la causa del null. El indicador y la columna original la preservan.
Control / evidencia	3 null en AREA_LIMPIA; QC14 aprobado.

STATUS

Elemento	Detalle
Problemas encontrados	Cinco categorías administrativas legibles pero en mayúsculas.
Regla ejecutada	Crear STATUS_LIMPIO y STATUS_COD con catálogo nominal.
Justificación	Facilita comparación y mantiene etiquetas aptas para informes.
Riesgo y mitigación	Confundir código con jerarquía. Se documenta como nominal.
Control / evidencia	0 códigos faltantes; QC17 aprobado.

MODALIDAD

Elemento	Detalle
Problemas encontrados	Dos categorías; requiere presentación ortográfica con diéresis y tilde.
Regla ejecutada	Crear MODALIDAD_LIMPIA y MODALIDAD_COD; conservar original.
Justificación	Evita variantes de escritura en resultados.
Riesgo y mitigación	Eliminar diacríticos. Las etiquetas finales son Monolingüe y Bilingüe.
Control / evidencia	11,130 monolingües y 473 bilingües; catálogo completo.

JORNADA

Elemento	Detalle
Problemas encontrados	Seis valores crudos; 1,072 filas dicen SIN JORNADA.
Regla ejecutada	Crear JORNADA_LIMPIA y código; transformar SIN JORNADA a null, marcar JORNADA_INFORMADA=0 y conservar original.

Elemento	Detalle
Justificación	Una ausencia no debe competir con jornadas reales.
Riesgo y mitigación	Perder la razón del null. Original e indicador permanecen.
Control / evidencia	1,072 null en JORNADA_LIMPIA; QC15 aprobado.

PLAN

Elemento	Detalle
Problemas encontrados	Trece categorías con paréntesis, acentos y capitalización heterogénea.
Regla ejecutada	Crear PLAN_LIMPIO y PLAN_COD mediante catálogo nominal; conservar original.
Justificación	Evita divergencias posteriores en filtros y tablas.
Riesgo y mitigación	Asignar un orden inexistente. El código es estrictamente nominal.
Control / evidencia	13 categorías documentadas y sin códigos faltantes.

DEPARTAMENTAL

Elemento	Detalle
Problemas encontrados	26 denominaciones administrativas; texto en mayúsculas.
Regla ejecutada	Crear DEPARTAMENTAL_LIMPIO y código nominal con catálogo; conservar original.
Justificación	Permite agrupar oficinas sin perder su rótulo institucional.
Riesgo y mitigación	Confundir oficina administrativa con departamento geográfico. Ambas variables permanecen separadas.
Control / evidencia	26 etiquetas documentadas y códigos completos.

5.1 Resumen de reglas y filas afectadas

ID	Variables	Acción	Filas afectadas
R01	Todas	Carga como texto y conservación del esquema crudo.	11,603
R02	Campos textuales	Unicode NFC, trim, espacios y puntuación.	64
R03	DISTRITO	Null para vacíos o formatos incompletos; estado separado.	591
R04	DEPARTAMENTO/MUNICIPIO	Etiquetas legibles y geografía de 23 orígenes / 22 departamentos.	11,603
R05	ESTABLECIMIENTO	Capitalización española, tildes respaldadas y clave auxiliar.	11,591

ID	Variables	Acción	Filas afectadas
R06	DIRECCION	Normalización conservadora; null solo en vacíos o puntuación aislada.	11,599
R07	TELEFONO	Texto normalizado, extracción de candidatos y estado.	11,600
R08	SUPERVISOR/DIRECTOR	Null para ausencias y presentación conservadora.	2,631
R09	AREA	SIN ESPECIFICAR a null en AREA_LIMPIA; indicador y original.	3
R10	JORNADA	SIN JORNADA a null en JORNADA_LIMPIA; indicador y original.	1,072
R11	Categorías	Códigos nominales estables en columnas nuevas.	11,603
R12	Duplicados	No eliminar filas: CODIGO es único y no hay duplicados exactos.	0

5.2 Tabla de transformaciones exigida

La siguiente tabla usa exactamente las cinco columnas solicitadas por la guía 2026. Registros afectados cuenta las celdas cuyo valor analítico difiere del valor crudo, incluido el paso explícito a null cuando corresponde.

Variable	Problema detectado	Transformación	Registros afectados	Justificación
CODIGO	Sin problemas de integridad; riesgo de perder ceros si se importa como número.	Conservar como string, aplicar trim y validar ###-##-####-46.	0	El patrón es estable y la unicidad puede probarse.
DISTRITO	Vacíos y valores incompletos que no cumplen ###-### o ##-##-####.	Conservar original; usar null en DISTRITO_LIMPIO cuando no sea completo y clasificar estado.	591	Evita inventar componentes y separa validez de ausencia.
DEPARTAMENTO	Ciudad Capital aparece como origen separado del departamento Guatemala.	Crear DEPARTAMENTO_LIMPIO y DEPARTAMENTO_ANALISIS; codificar 22 departamentos.	11,603	Preserva la procedencia y evita doble conteo territorial.
MUNICIPIO	Mezcla municipios con zonas capitalinas y carece de código explícito.	Normalizar ortografía, distinguir tipo de ubicación y derivar código desde CODIGO fuera de la capital.	11,603	La regla está respaldada por la estructura del identificador y el origen.
ESTABLECIMIENTO	Mayúsculas, tildes omitidas, espacios/puntuación y nombres iguales o similares.	Unicode NFC, espacios, capitalización española, tildes respaldadas, original permanente y detección de candidatos.	11,591	Produce texto utilizable sin sustituir nombres por similitud.
DIRECCION	Espacios, puntuación, abreviaturas y valores vacíos.	Normalización mecánica conservadora; null solo si no hay contenido utilizable.	11,599	Mejora legibilidad sin geocodificar ni inventar datos.

Variable	Problema detectado	Transformación	Registros afectados	Justificación
TELEFONO	Vacíos, separadores múltiples, prefijo 502 y formatos no interpretables.	Extraer bloques válidos de ocho dígitos; formato #####-####; null si no es interpretable; conservar original y estado.	11,600	Permite validación automática y no inventa dígitos.
SUPERVISOR	Vacíos, mayúsculas y presentación inconsistente.	Normalización conservadora y null para ausencia real; conservar original.	11,600	Facilita informes sin crear identidades de persona.
DIRECTOR	Alta ausencia, marcadores y presentación inconsistente.	Marcadores/vacíos a null, estado de ausencia y normalización conservadora.	11,597	El null tiene significado y no se imputa un nombre.
NIVEL	Etiqueta en mayúsculas; dominio esperado único.	Mapear a Diversificado y validar dominio.	11,603	La consulta se restringe al nivel solicitado.
SECTOR	Categoría nominal en mayúsculas.	Etiquetas legibles, catálogo cerrado y código nominal.	11,603	Evita variantes posteriores y mantiene interpretación.
AREA	SIN ESPECIFICAR no es una tercera área real.	Urbana/Rural; SIN ESPECIFICAR a null, con original e indicador.	11,603	Representa correctamente la ausencia semántica.
STATUS	Mayúsculas y tildes omitidas en categorías.	Normalizar etiquetas, validar catálogo y asignar código nominal.	11,603	Un catálogo cerrado evita variantes ortográficas.
MODALIDAD	MONOLINGUE/BILINGUE sin diéresis o tilde.	Corregir a Monolingüe/Bilingüe y codificar nominalmente.	11,603	Restituye ortografía española sin cambiar significado.
JORNADA	SIN JORNADA es ausencia semántica.	Jornadas reales en JORNADA_LIMPIA; SIN JORNADA a null, con indicador y original.	11,603	Evita tratar ausencia como categoría sustantiva.
PLAN	Mayúsculas, puntuación compacta y tildes.	Catálogo explícito, etiqueta legible y código nominal.	11,603	Controla todas las variantes del dominio observado.
DEPARTAMENTAL	Mayúsculas, nombres territoriales y tildes.	Normalización ortográfica conservadora y código nominal.	11,603	Facilita agrupación manteniendo el texto original.

6. Resultados de la limpieza

La tasa de conservación fue 100%: $(11,603 / 11,603) \times 100$. No se eliminaron registros, porque la llave CODIGO es íntegra y no existen duplicados exactos. Las transformaciones se expresan como columnas nuevas y una bitácora de cambios registra, por fila y variable, el valor original, el valor limpio y la regla aplicada.

6.1 Calidad antes y después

Métrica	Antes	Después	Cambio
Registros	11,603	11,603	0
Variables	17	59	42
Valores faltantes en 17 variables comparables	5,253	5,370	117
Porcentaje faltante en 17 variables comparables	2.6631	2.7224	0.0593
Variables con al menos un faltante	8	8	0
Duplicados exactos	0	0	0
Posibles duplicados parciales (pares)	13,031	13,031	0
Pares candidatos sin decisión documentada	13,031	0	-13,031
Variables con formato inconsistente	3	0	-3
Variables con tipo incorrecto según esquema	0	0	0
Variables con categorías fuera de catálogo	0	0	0
Categorías inconsistentes	0	0	0
Errores corregidos	0	174,608	174,608

El total de null analíticos aumenta en 117 celdas (de 5,253 a 5,370). Esto no es un deterioro: 69 distritos incompletos y 48 teléfonos no interpretables dejan de aparentar ser valores válidos. Sus textos originales permanecen disponibles. A la vez, las tres variables con formatos inconsistentes quedan en cero y los 13,031 pares candidatos pasan de no tener decisión a contar con una decisión documentada.

6.2 Ejemplos de transformación

Variable	Fuente	Presentación analítica
DEPARTAMENTO	ALTA VERAPAZ	Alta Verapaz
MUNICIPIO	COBAN	Cobán
ESTABLECIMIENTO	INSTITUTO MIXTO NOCTURNO FRANCISCO MARROQUIN	Instituto Mixto Nocturno Francisco Marroquín
ESTABLECIMIENTO	INSTITUTO DE TURISMO Y AVIACION DEL NORTE I.T.A.N	Instituto de Turismo y Aviación del Norte I.T.A.N
DIRECCION	6A. AVENIDA 1-15 ZONA 4	6A. Avenida 1-15, Zona 4
TELEFONO	77945104	7794-5104
SUPERVISOR	JORGE EDUARDO PAQUE LAZARO	Jorge Eduardo Paque Lázaro
TELEFONO	formato no interpretable	null; original y estado conservados

Variable	Fuente	Presentación analítica
DIRECTOR	--	null; estado = Marcador

Interpretación: Estas correcciones no certifican que cada nombre propio coincida con una fuente externa; son normalizaciones reproducibles respaldadas por reglas conservadoras. Para usos legales o administrativos debe verificarse el valor con MINEDUC y consultar siempre la columna original.

7. Análisis descriptivo del conjunto final




Figura 2. Distribuciones principales del conjunto limpio.

7.1 Sector y estado

Sector	Filas	%
Privado	9,648	83.15%
Oficial	1,488	12.82%
Cooperativa	292	2.52%

Sector	Filas	%
Municipal	175	1.51%

Estado	Filas	%
Abierta	6,702	57.76%
Cerrada temporalmente	2,930	25.25%
Cerrada definitivamente	1,813	15.63%
Temporal por títulos	109	0.94%
Temporal por nombramiento	49	0.42%

El 83.15% de los servicios pertenece al sector privado. El 57.76% figura abierto; el 25.25% está cerrado temporalmente y el 15.63% cerrado definitivamente. Estas cifras describen registros administrativos del archivo y no deben interpretarse como matrícula, capacidad instalada ni edificios únicos.

7.2 Área, jornada y modalidad

Área	Filas	%
Urbana	9,271	79.90%
Rural	2,329	20.07%
No informado	3	0.03%

Jornada	Filas	%
Doble	3,705	31.93%
Vespertina	3,344	28.82%
Matutina	2,943	25.36%
No informado	1,072	9.24%
Nocturna	413	3.56%
Intermedia	126	1.09%

Modalidad	Filas	%
Monolingüe	11,130	95.92%
Bilingüe	473	4.08%

La clasificación urbana representa 79.90% y la rural 20.07%; tres registros no informan el área. Las jornadas más frecuentes son Doble (31.93%), Vespertina (28.82%) y Matutina (25.36%). El 9.24% no informa jornada. La modalidad “Monolingüe” representa el 95.92%.

7.3 Ubicación y teléfonos

Ubicación	Filas	%
Otros municipios	9,442	81.38%
Ciudad Capital	2,161	18.62%

Estado del teléfono	Filas	%
Válido único	10,501	90.50%
Vacío	933	8.04%
Válidos múltiples	121	1.04%
Formato no estándar	48	0.41%

Ciudad Capital concentra 2,161 registros (18.62%). Después de integrarla a Guatemala, el departamento analítico de Guatemala suma 3,805 filas (32.79%). En teléfonos, 90.01% contiene un único número válido, 1.05% varios números válidos, 0.90% un formato no estándar que debe revisarse y 8.04% está vacío.

8. Control de calidad y reproducibilidad

ID	Control	Cumple	Esperado	Observado
QC01	Filas conservadas	Sí	11,603	11,603
QC02	CODIGO único	Sí	11,603	11,603
QC03	CODIGO cumple patrón	Sí	0	0
QC04	Duplicados exactos finales	Sí	0	0
QC05	Sin espacios iniciales/finales en textos limpios	Sí	0	0
QC06	Teléfonos limpios con formato consistente	Sí	0	0
QC07	Departamentos pertenecen al catálogo de 22	Sí	22	22
QC08	Municipios y códigos pertenecen al catálogo observado	Sí	334	334
QC09	Tipos de variables codificadas según esquema	Sí	0	0
QC10	Sin variantes duplicadas de categorías	Sí	0	0

ID	Control	Cumple	Esperado	Observado
QC11	Sin categorías fuera de dominios limpios	Sí	0	0
QC12	Controles de consistencia cruzada	Sí	0	0
QC13	Ciudad Capital coincide con origen	Sí	0	0
QC14	Zona solo informada en Ciudad Capital	Sí	0	0
QC15	AREA_INFORMADA coherente	Sí	0	0
QC16	JORNADA_INFORMADA coherente	Sí	0	0
QC17	Originales preservados	Sí	16	16
QC18	Todos los candidatos tienen decisión	Sí	13,031	13,031
QC19	Duplicados parciales no eliminados automáticamente	Sí	0	0
QC20	Libro de códigos cubre el dataset	Sí	59	59
QC21	Metadatos completos en todas las filas	Sí	11,603	11,603
QC22	Snapshot crudo conserva huella SHA-256	Sí	e7b9f1056e17	e7b9f1056e17
QC23	Código coincide con departamento	Sí	0	0
QC24	Municipio coincide con departamento	Sí	0	0
QC25	Zona solo en Ciudad Capital	Sí	0	0
QC26	Etiquetas y códigos consistentes	Sí	0	0
QC27	Indicadores consistentes	Sí	0	0

Los 27 controles pasaron exitosamente. Además, el notebook conserva sus salidas de ejecución: 18 celdas de código tienen número de ejecución consecutivo, no existen trazas de error y las tablas, decisiones y figuras corresponden a la misma corrida que generó los archivos finales.

8.1 Consistencia entre variables

ID	Validación cruzada	Inconsistencias	Cumple
CV01	Prefijo departamental de CODIGO coincide con departamento	0	Sí
CV02	Prefijo municipal de CODIGO coincide con MUNICIPIO_COD_FUENTE	0	Sí
CV03	Ciudad Capital coincide con categoría de origen	0	Sí
CV04	Zona capital solo informada para Ciudad Capital	0	Sí
CV05	AREA_INFORMADA coincide con AREA_LIMPIA	0	Sí
CV06	JORNADA_INFORMADA coincide con JORNADA_LIMPIA	0	Sí
CV07	TELEFONO_PRINCIPAL es coherente con TELEFONO_ESTADO	0	Sí

```

assert controles["CUMPLE"].all()
assert len(df_limpio) == len(df_raw) == 11603
assert df_limpio["CODIGO"].is_unique
assert df_limpio["DEPARTAMENTO_ANALISIS"].nunique() == 22
assert candidatos_duplicados["DECISION"].notna().all()
assert validaciones_cruzadas["INCONSISTENCIAS"].eq(0).all()

```

9. Libro de códigos y entregables

El libro de códigos documenta un total de 59 variables. Para cada una indica significado, tipo, admisión de null, dominio, valores posibles, tratamiento, origen, método de cálculo, utilidad, fecha de extracción, fuente y versión. Los catálogos de codificación se incluyen en CSV y Excel. Todos los códigos categóricos son nominales y sus etiquetas legibles se conservan.

Archivo	Finalidad
Proyecto_1_MINEDUC_2026_Final_Ejecutado.ipynb	Notebook reproducible, ejecutado y con análisis 2026.
Informe_Final_Proyecto_1_MINEDUC.docx / .pdf	Informe final formal y versión fija para entrega.
Libro_de_Codigos_MINEDUC.docx / .pdf / .md	Descripción general, 59 variables, tratamientos, derivaciones y catálogos.
Proyecto_1_MINEDUC_2026_Datos_Libro_Codigos.xlsx	Panel, datos analíticos, diagnóstico, reglas, catálogos y controles.
establecimientos_diversificado_limpio.csv	Conjunto nacional completo de 11,603 × 59.
establecimientos_diversificado_limpio_analitico.csv	Vista de 11,603 × 42 para uso práctico.
datos_crudos_establecimientos_diversificado.csv	Consolidado crudo inalterado.
bitacora_cambios_detalle.csv	Trazabilidad por fila y variable.
catalogos_codificacion.csv	Relación de valores, etiquetas y códigos nominales.
candidatos_duplicados_parciales.csv	13,031 pares, similitud, evidencia, decisión y justificación.
calidad_antes_despues.csv	Doce métricas de calidad comparables.
catalogo_territorial_observado.csv	334 municipios presentes y 22 zonas capitalinas.
resumen_transformaciones.csv	Tabla exigida de cinco columnas para las 17 variables.

10. Limitaciones

- El archivo representa códigos de servicio educativo y no necesariamente planteles físicos únicos.
- Las cifras describen el estado de la fuente en la fecha de procesamiento; el portal puede cambiar posteriormente.

- No se imputaron nombres, teléfonos, distritos ni jornadas sin evidencia; null conserva la ausencia.
- Los 48 teléfonos no estándar quedan como null analítico y requieren revisión manual o contraste con una fuente oficial; el valor original no se pierde.
- El catálogo territorial observado cubre 334 de los 340 municipios nacionales reportados por SEGEPLAN; los otros seis no aparecen con Diversificado en este snapshot.
- Se recomiendan 2,063 revisiones manuales entre los pares parciales; no se efectuaron fusiones sin evidencia oficial.
- La normalización ortográfica mejora presentación, pero un nombre propio crítico debe verificarse contra el registro oficial antes de uso legal.
- Las particiones por origen se derivaron del consolidado crudo disponible; su finalidad es auditar la unión nacional.

11. Conclusiones

El proyecto cumple la ruta completa solicitada en la guía 2026: conserva los datos crudos en CSV, diagnostica su estructura y calidad mediante código, ejecuta reglas justificadas, documenta cada cambio, analiza duplicados exactos y parciales, verifica consistencia entre variables, compara calidad antes/después, produce una unión nacional limpia y entrega un libro de códigos multiformato. La decisión de mantener originales y derivados permite mejorar legibilidad sin perder evidencia.

La codificación nominal de variables categóricas —incluida la distinción Ciudad Capital/Otros municipios— reduce la cantidad de inconsistencias futuras. El tratamiento variable por variable de los faltantes evita convertir categorías semánticas de ausencia en valores reales o imputar información inexistente.

Referencia

Ministerio de Educación de Guatemala. (s. f.). Búsqueda de centros educativos autorizados por el Mineduc. http://www.mineduc.gob.gt/BUSCAESTABLECIMIENTO_GE/

Secretaría de Planificación y Programación de la Presidencia. (2026). Cálculo matemático para la asignación constitucional a las municipalidades 2026. <https://datos.segeplan.gob.gt/es/dataset/calculo-matematico-para-la-asignacion-constitucional-a-las-municipalidades-2026>