

Proyecto 1. Obtención y Limpieza de los datos

INTRODUCCIÓN:

Los tipos y las fuentes de datos como se encuentran en las organizaciones son realmente diversos. El primer trabajo de un científico de datos es acceder a las fuentes y preparar los datos para que puedan ser analizados. Usualmente esto lleva un gran trabajo, pero sin hacerlo, el riesgo de llegar a resultados erróneos es demasiado alto. Con la realización de este proyecto, no solo aprenderá a utilizar las herramientas que le permitan acceder a los datos, sino a limpiarlos, haciéndolo de la forma más transparente posible.

Competencias:

- Utiliza las herramientas que tiene a su disposición para obtener los datos de la fuente especificada.
- Modifica los datos que obtuvo realizando procesos de limpieza que allanen el camino del analista de datos.
- Hace el proceso de limpieza transparente y reproducible para cualquiera que lo desee verificar.
- Elabora un “Code Book” detallado que contenga todos los metadatos que sean necesarios para analizar los datos.

ACTIVIDADES

1. Descargue los datos de los establecimientos educativos de todo el país que lleguen hasta el nivel de diversificado (NIVEL ESCOLAR: DIVERSIFICADO). Los puede encontrar en el siguiente vínculo: http://www.mineduc.gob.gt/BUSCAESTABLECIMIENTO_GE/
2. Guarde los datos crudos en archivos .csv.
3. **Análisis del estado inicial de los datos:** Elabore un diagnóstico del conjunto de datos que, como mínimo incluya:
 - a. Número de registros y variables.
 - b. Tipo de dato de cada variable.
 - c. Cantidad y porcentaje de valores faltantes por variable.
 - d. Cantidad de valores únicos.
 - e. Cantidad de registros duplicados exactos.
 - f. Variables con valores fuera de dominio o inconsistentes.
 - g. Variables con formatos inconsistentes.
 - h. Identificación de problemas potenciales de calidad de datos.

Este análisis debe estar respaldado por tablas y estadísticas generadas usando código.

4. **Plan de limpieza:** Antes de modificar los datos deberá elaborar un plan de limpieza donde describa, para cada variable:
 - a. Problemas encontrados.

- b. Regla que utilizará para corregirlos y por qué cree que funcionará.
 - c. Riesgos asociados a la transformación.
- 5. **Limpieza del conjunto de datos:** Realice todas las operaciones necesarias para obtener un conjunto de datos consistente, reproducible y listo para el análisis. Deberá revisar **todas las variables** del conjunto de datos considerando los siguientes aspectos cuando sean aplicables:
 - a. Explique cómo fueron tratados:
 - i. Valores faltantes y NA.
 - ii. Cadenas vacías.
 - iii. Espacios en blanco.
 - iv. Valores como "N/A", "NULL", "-", ".", "Sin dato", etc.
 - b. Verifique que cada variable tenga el **tipo de dato** apropiado.
 - Por ejemplo:
 - números almacenados como texto,
 - fechas almacenadas como cadenas,
 - variables categóricas codificadas incorrectamente.
 - c. Normalización de texto. Revise:
 - i. espacios iniciales y finales,
 - ii. espacios múltiples,
 - iii. uso consistente de mayúsculas y minúsculas,
 - iv. tildes,
 - v. caracteres especiales,
 - vi. signos de puntuación innecesarios,
 - vii. caracteres invisibles.
 - d. Consistencia de categorías. Justifique cualquier unificación realizada. Detecte categorías escritas de diferentes maneras:
 - i. Por ejemplo:
 - Guatemala
 - GUATEMALA
 - Guatemala
 - Guatemplá
 - Guatemala.
 - e. Formatos. Verifique formatos consistentes para variables como:
 - i. teléfonos,
 - ii. códigos,
 - iii. direcciones,
 - iv. nombres.
 - f. Valores inválidos
 - i. Identifique valores que no pertenecen al dominio esperado.
 - Ejemplos:
 - departamentos inexistentes,
 - municipios inválidos,

- teléfonos con letras o con menos dígitos,
 - códigos imposibles.
 - g. Registros duplicados
 - i. Debe buscar tanto:
 - 1. duplicados exactos,
 - 2. duplicados parciales.
 - a. Para los duplicados parciales se sugiere utilizar alguna técnica basada en similitud de cadenas (por ejemplo Levenshtein, Jaro-Winkler, RapidFuzz o equivalente).
 - ii. No elimine automáticamente los registros. Analice cada caso y documente la decisión tomada.
 - h. Consistencia entre variables
 - i. Revise que los valores de distintas variables no se contradigan entre sí.
 - ii. Documente cualquier inconsistencia encontrada.
 - i. Variables derivadas
 - i. Si crea nuevas variables, deberá justificar:
 - por qué fueron creadas,
 - cómo fueron calculadas,
 - cuál es su utilidad.
 - Todas deberán aparecer en el Libro de Códigos.
6. Registro de transformaciones: Toda modificación realizada deberá quedar documentada en una tabla como la siguiente:

Variable	Problema detectado	Transformación	Registros afectados	Justificación

Todo el proceso deberá ser completamente reproducible.

7. Validación del conjunto limpio: Al finalizar la limpieza deberá ejecutar pruebas automáticas que verifiquen la calidad del conjunto de datos. Deberá comprobar que:
- no existan registros duplicados exactos;
 - no existan espacios al inicio o final de textos;
 - los teléfonos tengan un formato consistente;
 - los nombres de departamentos y municipios pertenezcan al catálogo correspondiente;
 - las variables tengan el tipo de dato esperado;
 - no existan categorías duplicadas por diferencias de escritura;
 - no existan valores inválidos detectados durante el diagnóstico inicial.
8. Informe de calidad de los datos: El informe deberá comparar el estado del conjunto de datos antes y después de la limpieza. Deberá incluir una tabla como la siguiente:

Métrica	Antes	Después
Registros		
Variables		

Valores faltantes		
Variables con NA		
Duplicados exactos		
Posibles duplicados		
Variables con formato inconsistente		
Variables con tipo incorrecto		
Categorías inconsistentes		
Errores corregidos		

En la que ponga la siguiente información:

Registros: Número total de filas del conjunto de datos. Debe justificarse si cambió (por ejemplo, eliminación de duplicados exactos).

Variables: Número total de columnas. Si se agregaron variables derivadas o se eliminaron columnas vacías, debe explicarse.

Valores faltantes: Número y porcentaje total de celdas con valores faltantes (NA, NULL, cadenas vacías, etc.).

Variables con NA: Cantidad de variables que contienen al menos un valor faltante.

Duplicados exactos: Número de registros idénticos en todas sus columnas.

Posibles duplicados: Número de registros identificados como posibles duplicados mediante similitud de nombres, direcciones o teléfonos. Debe indicarse cuántos fueron corregidos, fusionados o conservados.

Variables con formato inconsistente: Cantidad de variables que presentaban problemas de formato (espacios, mayúsculas, teléfonos, fechas, etc.).

Variables con tipo incorrecto: Cantidad de variables cuyo tipo de dato no coincidía con el esperado (por ejemplo, números almacenados como texto).

Categorías inconsistentes: Número de categorías diferentes que representaban el mismo valor (por ejemplo, "Guatemala", "GUATEMALA", "guatemala").

Errores corregidos: Total de correcciones realizadas durante la limpieza, o un resumen por tipo de error.

9. **Generación del conjunto limpio:** Genere un único conjunto de datos, con la información de todos los departamentos que cumpla las siguientes condiciones:
 - a. estructura consistente;
 - b. tipos de datos correctos;
 - c. nombres de variables descriptivos;
 - d. formato uniforme en todas las columnas;
 - e. ausencia de errores detectados durante la fase de validación.
10. **Libro de códigos:** Para cada variable el Libro de Códigos deberá incluir:
 - a. Descripción de la variable;
 - b. Tipo de dato;
 - c. Dominio permitido;

- d. Valores posibles;
 - e. Tratamiento aplicado durante la limpieza;
 - f. Variables derivadas (si existen);
 - g. Fecha de extracción;
 - h. Fuente de los datos;
 - i. Versión del conjunto limpio.
11. Todo el proceso deberá ser completamente reproducible.

EVALUACIÓN

- **(5 puntos)** Obtención y documentación y unión de los datos.
- **(15 puntos)** Análisis del estado de los datos crudos: Se hace un análisis detallado del estado de los datos antes de comenzar las operaciones de limpieza. (Diagnóstico)
- **(10 puntos)** Plan de limpieza. Se elabora el plan de limpieza en el que especifican que problema tiene el campo, cual es la posible transformación y los riesgos de aplicarlas.
- **(30 puntos)** Se hace una limpieza de calidad sobre todas las variables del conjunto de datos total, realizando todas las operaciones propuestas en esta guía. Se demuestra la capacidad para identificar registros repetidos tanto exactos como parciales.
- **(10 puntos)** Se implementan pruebas que permitan verificar que el conjunto de datos cumple las reglas de calidad establecidas
- **(10 puntos)** Se evalúa la capacidad para demostrar objetivamente la mejora obtenida después del proceso de limpieza.
- **(10 puntos)** Libro de códigos. El libro de código debe ser comprensible, estar bien detallado y organizado. Contiene los metadatos necesarios para comprender el conjunto de datos, incluidas las fechas en las que se extrajeron y la fuente.
- **(10 puntos)** Generación del conjunto de datos Limpios. Se genera un solo conjunto de datos con la información de todos los departamentos. Los datos generados están limpios y pueden utilizarse para hacer análisis.

NOTA: Todos los integrantes del grupo deben contribuir al repositorio y code book. No se evaluará a quien no tenga contribuciones significativas.

MATERIAL A ENTREGAR

- Archivo .r, .rmd, .ipynb, o .py, con el código de las acciones tomadas desde que se carga el conjunto de datos hasta que se termina de limpiar.
- Link del repositorio con el código, los datos y el libro de códigos.
- Documento del Google docs o markdown donde se trabajó el libro de códigos
- Archivo pdf, con el libro de códigos
- Archivo csv con los datos limpios